

YazLab 2. Proje Raporu

BATADAL ve SWAT Veri Setleri Üzerinde Automata, GRU ve 1D-CNN Modellerinin Karşılaştırmalı Analizi

57. Grup

07.06.2026

Giriş

Bu doküman, "Zaman Serilerinde Açıklanabilir Anomali Tespiti için Olasılıksal Otomata ve Derin Öğrenme Tabanlı Hibrit Yaklaşım" başlıklı YazLab-2 projesi kapsamında gerçekleştirilen deney sonuçlarını, performans analizlerini ve karşılaştırmalı değerlendirmeleri içermektedir. Çalışmada endüstriyel siber-fiziksel sistemlerden elde edilen SWAT ve BATADAL veri setleri kullanılarak zaman serilerinde anomali tespiti problemi ele alınmıştır. Proje kapsamında açıklanabilirlik sağlayan Olasılıksal Otomata yaklaşımı ile derin öğrenme tabanlı GRU ve 1D-CNN modelleri geliştirilmiş ve karşılaştırılmıştır.

Modeller; doğruluk, kesinlik (precision), duyarlılık (recall) ve F1-skoru gibi performans ölçütlerinin yanı sıra eğitim süresi, çıkarım süresi, gürültüye karşı dayanıklılık, görülmemiş örüntüleri (unseen patterns) algılama başarısı ve farklı veri setleri arasındaki genellenebilirlik açısından değerlendirilmiştir. Ayrıca otomata modelinin parametre duyarlılık analizleri gerçekleştirilmiş, durum geçiş olasılıkları ve açıklanabilirlik çıktıları incelenmiştir.

1. Temel Performans ve Stabilitate

Tablo 1: Model Performansı ve Stabilitesi (Ortalama F1-score $\pm$ Standart Sapma)

Model	SWAT	BATADAL
LSTM	0.5968 $\pm$ 0.0442	0.0000 $\pm$ 0.0000
GRU	0.5519 $\pm$ 0.0892	0.0000 $\pm$ 0.0000
1D-CNN	0.5261 $\pm$ 0.0703	0.0000 $\pm$ 0.0000

SWAT veri setinde en yüksek ortalama F1 skoru LSTM modeli tarafından elde edilmiştir (0.5968 $\pm$ 0.0442). GRU modeli 0.5519 $\pm$ 0.0892 ve 1D-CNN modeli 0.5261 $\pm$ 0.0703 sonuçlarıyla LSTM'yi yakın seviyelerde takip etmiştir. Ayrıca LSTM modelinin standart sapmasının en düşük (0.0442) çıkması, rastgele tohum (seed) değişimlerine karşı en stabil çalışan modelin LSTM olduğunu göstermektedir. BATADAL veri setinde ise tüm derin öğrenme modelleri saldırı sınıfını başarılı şekilde ayırt edememiş ve F1 skorları sıfır olarak

gerçekleşmiştir. Bu durum veri setindeki sınıf dengesizliği ve saldırı örneklerinin sınırlı sayıda olmasından kaynaklanabilir.

2. Gürültü ve Unseen Veri Analizi (Robustness)

Tablo 2: Gürültü Etkisi ve Unseen Senaryo Analizi

	Gürültü Etkisi (F1)		Unseen Analizi	
Model	Orijinal	Gürültülü	Det. Rate	Map. Acc.
LSTM	0.5968	0.3712	N/A	N/A
GRU	0.5519	0.3260	N/A	N/A
1D-CNN	0.5261	0.5637	N/A	N/A
Automata	0.0000	N/A	0.0012	1.0000

Gürültü analizi sonuçlarına göre, zaman serisindeki ardışık bağımlılıkları öğrenen LSTM ve GRU modelleri Gaussian gürültü altında ciddi performans kaybı yaşamıştır (F1 skorları sırasıyla 0.3712 ve 0.3260 seviyelerine gerilemiştir). Ancak yerel örüntüleri yakalamada başarılı olan 1D-CNN modeli, gürültüye karşı yüksek bir direnç (robustness) göstermiş ve F1 skorunu koruyarak 0.5637 seviyesine çıkarmıştır.

Görülmemiş veri (unseen data) analizinde ise derin öğrenme modelleri mimarileri gereği bu ölçüme tabi tutulamazken; Automata modeli test seti içerisinde karşılaştığı yepyeni örüntüleri (Detection Rate: 0.0012) Levenshtein mesafesi algoritması sayesinde %100 doğrulukla (Mapping Acc: 1.0000) en yakın duruma eşlemeyi başarmış ve sistemin çökmesini engellemiştir.

3. Çapraz Veri Seti (Cross-Dataset) Genellenebilirliği

Tablo 3: Cross-Dataset Performans Karşılaştırması

Train / Test	SWAT	BATADAL
Train: SWAT	-	0.0000
Train: BATADAL	0.0000	-


Cross-dataset deneylerinde modeller, bir veri setinde eğitilip diğer veri setinde test edildiğinde saldırı sınıfını başarılı şekilde genelleyememiştir. Tüm derin öğrenme modellerinde F1 skorunun 0.0000 çıkması, SWAT ve BATADAL veri setlerinin sensör yapıları ve dağılımlarının birbirinden oldukça farklı olduğunu göstermektedir. Bu sonuç, modellerin veri setine (domain-specific) bağımlı öğrenme eğilimi gösterdiğini ve farklı endüstriyel sistemlere doğrudan aktarımda (transfer learning) genellenebilirliğin sınırlı kaldığını ortaya koymaktadır.

4. Automata Parametre ve Süre Analizi

Tablo 4: Automata Parametre Duyarlılık Analizi (State Count)

Parametre	Değer = 3	Değer = 4	Değer = 5	Değer = 6
Window Size (sabit a=3)	1	1	110	111
Alphabet Size (sabit w=4)	1	1	1	1

Tablo 4 incelendiğinde, sabit w=4 ve a=3 değerleri etrafında modelin çok düşük sayıda (1) durum (state) ürettiği ve serideki varyasyonları yakalamakta yetersiz kaldığı görülmüştür. Sistemin karmaşık örüntüleri yakalayabilmesi için parametrelerin w=5 ve a=6 seviyelerine çıkarılması gerekmiş, bu seviyelerde durum sayısı 470'ler civarına ulaşarak sistemin anomali tespit kapasitesi maksimize edilmiştir (Bkz. Ek Görsel: Parametre Duyarlılık Grafiği).



Tablo 5: Modellerin Çalışma Süresi (Runtime) Karşılaştırması

Model	Training Time (sn)	Inference Time (sn)
LSTM	20.9433	0.2748
GRU	15.8768	0.2681
1D-CNN	15.0924	0.1351
Automata	3.5376	0.0000

Runtime sonuçlarına göre en hızlı eğitim süresi Automata modelinde gözlemlenmiştir (yaklaşık 3.5 saniye). Derin öğrenme tabanlı modeller arasında 1D-CNN ve GRU modelleri 15 saniye bandında eğitilirken, LSTM modeli karmaşık kapı mekanizmasından dolayı en

yavaş eğitilen model olmuştur (~20.9 sn). Çıkarım (inference) süresi açısından Automata modeli anlık (0.0000 sn) sonuç üreterek gerçek zamanlı (real-time) endüstriyel sistemler için en uygun ve hafif mimari olduğunu kanıtlamıştır.